



# Clase 2: Métodos Experimentales

---

Santiago Olivella

July 19, 2017

Profesor Asistente de la Universidad de Carolina de Norte, Chapel Hill

- Mecanismos de Asignación Aleatoria
- Evaluación de hipótesis
- Límites de Confianza
- Análisis de poder

# Mecanismos de asignación

- Un **mecanismo de asignación** es una distribución de probabilidad sobre el conjunto  $\mathcal{D}$ .
- Tres características:
  - No confundido:  $\Pr(\mathbf{D}|\mathbf{X}, \mathbf{Y}(1), \mathbf{Y}(0)) = \Pr(\mathbf{D}|\mathbf{X})$
  - Individualístico:  $\Pr(D_i|\mathbf{X}) = \Pr(D_i|\mathbf{x}_i)$
  - Probabilístico:  $0 < \Pr(D_i|\mathbf{x}_i) < 1$
- Podemos clasificar los distintos tipos de experimentos por el tipo de mecanismo de asignación del tratamiento.

# Tipos de Experimentos Aleatorizados

- Experimento de ensayo Bernoulli (¿probabilístico?):

$$\Pr(\mathbf{D}|\mathbf{X}) = \prod_{i=1}^N e(\mathbf{x}_i)^{D_i} (1 - e(\mathbf{x}_i))^{1-D_i}$$

- Experimento completamente aleatorizado:

$$\Pr(\mathbf{D}|\mathbf{X}) = \begin{cases} \binom{N}{N_t}^{-1} & \text{si } \sum_i D_i = N_t \\ 0 & \text{de lo contrario} \end{cases}$$


- Experimento estratificado (para bloques  $B(i) \in \{1, \dots, J\}$ ; pares igualados es caso especial):

$$\Pr(\mathbf{D}|\mathbf{X}) = \begin{cases} \binom{N(j)}{N_t(j)}^{-1} & \text{si } \sum_{i:B(i)=j} D_i = N_t(j) \forall j \\ 0 & \text{de lo contrario} \end{cases}$$

# Tipos de Experimentos Aleatorizados


- La atribución causal en promedio es hecha posible por la aleatorización: los grupos de tratamiento son iguales, en esperanza, en todos los aspectos relevantes.
- Para una instancia: posibilidad del “bad draw” (falta de equilibrio en distribuciones de covariables para un experimento concreto).
- Bloques aseguran equilibrio en instancia observada, y mejoran precisión de estimación
- Especialmente útil cuando el número de unidades es pequeño.
- Mantra: **Estratifique lo que pueda, aleatorice lo demás** (Box et al. 1978).

# Ejemplo – Asignación GOTV (fuente: Erin Hartman)




# Ejemplo – Asignación GOTV (fuente: Erin Hartman)

Complete Randomization — Balance on Average




# Ejemplo – Asignación GOTV (fuente: Erin Hartman)





# Ejemplo – Asignación GOTV (fuente: Erin Hartman)

Block Randomization -- Ensures Balance



# Resultados Potenciales

Villa	Bloque	Y(I) Control	Y(I) Tratamiento
1	A	0	0
2	A	1	0
3	A	2	1
4	A	4	2
5	A	4	0
6	A	6	0
7	A	6	2
8	A	9	3
9	B	14	12
10	B	15	9
11	B	16	8
12	B	16	15
13	B	17	5
14	B	18	17

**Table 3.3** Listado de resultados potenciales para proyectos de obras públicas cuando son auditados( $Y(1)$ ) y cuando no son auditados ( $Y(0)$ )

Villa	Bloque	Todos participantes		Bloque A participantes		Block B participantes	
		$Y(0)$	$Y(1)$	$Y(0)$	$Y(1)$	$Y(0)$	$Y(1)$
1	A	0	0	0	0		
2	A	1	0	1	0		
3	A	2	1	2	1		
4	A	4	2	4	2		
5	A	4	0	4	0		
6	A	6	0	6	0		
7	A	6	2	6	2		
8	A	9	3	9	3		
9	B	14	12			14	12
10	B	15	9			15	9
11	B	16	8			16	8
12	B	16	15			16	15
13	B	17	5			17	5
14	B	18	17			18	17
Promedio		9.14	5.29	4.00	1.00	16.0	11.0
Varianza		40.41	32.49	7.75	1.25	1.67	17.0
Cov[ $Y(0), Y(1)$ ]		31.03		2.13		1.00	

	Todos participantes		Bloque A		Bloque B	
	$Y_i^c$	$Y_i^t$	$Y_i^c$	$Y_i^t$	$Y_i^c$	$Y_i^t$
Promedio	9.14	5.29	4.00	1.00	16.00	11.00
Varianza	40.41	32.49	7.75	1.25	1.67	17.00
Covarianza	31.03		2.13		1.00	

# Estimación del EPT con Asignación Aleatoria Estratificada

$$\text{SATE}_{\text{strat}} = \sum_{j=1}^J \frac{N(j)}{N} \text{SATE}_j$$

- Donde  $J$  es el numero de bloques y  $\frac{N(j)}{N}$  es la proporción de todos los participantes en el bloque  $j$
- Promedio ponderado del SATE en cada bloque.

# Nivel de Aleatorización

- ¿Cómo decidir unidad experimental? i.e. ¿a qué nivel administramos tratamiento? Algunas consideraciones:
  - Unidad de medición de variable de respuesta: no aleatorizar a nivel menor de medición.
  - Derrame: puede ocurrir a niveles bajos de aleatorización (algunos diseños ayudan en este caso)
  - Cumplimiento y atrición
  - Poder estadístico: niveles bajos de agregación más poder (fuerza opuesta a las anteriores).

# Prueba de Hipótesis según Fisher

- Podemos evaluar algunas conjeturas que nos entregan el listado completo de los resultados potenciales
- Una conjetura es la llamada “*hipótesis nula nítida*”: el efecto de tratamiento es constante para todas las observaciones (usualmente cero)
- Bajo esta hipótesis, e.g.  $Y_i(1) = Y_i(0)$ . En este caso podemos observar *ambos* resultados potenciales de cada observación
- Simulaciones de las asignación aleatoria entregan un distribución muestral exacta del efecto promedio del tratamiento en caso que utilizamos la “hipótesis nula nítida”

# Resultados Observables Presupuesto Local

	Porcentaje del presupuesto si el jefe de la villa es hombre	Porcentaje del presupuesto si el jefe de la villa es mujer
Villa 1	?	15
Villa 2	15	?
Villa 3	20	?
Villa 4	20	?
Villa 5	10	?
Villa 6	15	?
Villa 7	?	30



## Ejemplo: Aleatorización

- De esta tabla se genera un valor estimado de EPT de 6.5
- ¿Cuán probable es que podamos obtener un estimado tanto o más grande que 6.5 si el valor verdadero fuera cero en todas las observaciones?
- La probabilidad asumiendo que la hipótesis nula sea correcta (o el  $p$ -value), de interés en este caso evalúa una *hipótesis unilateral*, es decir que asumimos que cuando el jefe de la villa es mujer hay un incremento en la asignación presupuestaria para instalaciones de agua potable

## Ejemplo: Prueba bilateral - "1-tailed test"

- Basándonos en los resultados observados en la tabla, podemos calcular las 21 posible estimaciones del EPT que podrían haber sido generados si la hipótesis nula fuera verdad:  $\{-7.5, -7.5, -7.5, -4.0, -4.0, -4.0, -4.0, -4.0, -0.5, -0.5, -0.5, -0.5, -0.5, 3.0, 3.0, 6.5, 6.5, 6.5, 10.0, 10.0\}$
- Cinco de las estimaciones son mayores o iguales a 6.5. Por lo tanto, cuando evaluamos mediante un test unilateral en donde la jefe de la villa es mujer, asumimos que el presupuesto asignado a instalaciones de agua potable *aumenta*, y estamos concluyendo que hay una probabilidad de  $5/21 = 0.24$  de obtener un estimado mayor que 6.5 si es que la hipótesis nula es verdad.

## Ejemplo: Prueba bilateral - "2-tailed test"

- Si buscamos evaluar la *prueba de dos colas* - es decir si la jefe de la villa es mujer puede implicar un incremento o disminución en la asignación presupuestaria para instalaciones de agua potable
- Estaríamos calculando el "p-value" de obtener un número que es mayor o igual a 6.5 o bien menor o igual a -6.5. Un test de hipótesis bilateral considera todas las instancias en que los estimados son menores a iguales a 6.5 *en su valor absoluto*. Ocho de los estimados cualifican este criterio, por lo que el valor del "p-value" de dos colas es  $8/21 = 0.38$

# Señora Degustando Té

- Ronald Fisher, *The Design of Experiments*
- Experimento de té aleatorio:
  - 8 Copas idénticas preparadas
  - 4 tazas preparadas al azar con leche primero
  - 4 tazas preparadas al azar con leche después
- ¡La mujer clasificó correctamente todas las tazas!

# Señora Degustando Té

tazas	conjetura dama	orden real	escenarios			...
1	M	M	T	T	T	
2	T	T	T	T	M	
3	T	T	T	T	M	
4	M	M	T	M	M	
5	M	M	M	M	T	
6	T	T	M	M	T	
7	T	T	M	T	M	
8	M	M	M	M	T	
Número de conjeturas correctas		8	4	6	2	...

# Señora Degustando Té

```
## Randomization inference
```

```
## Real allocation
```

```
real_alloc <- c("M", "T", "T", "M", "M", "T", "T", "M")
```

```
## Possible allocations
```

```
library(gtools)
```

```
combs <- combinations(8,4)
```

```
## Dist nr. of correct guesses
```


```
n_correct <- apply(combs, 1  
  , function(guess){  
    guess_vec <- rep(NA, 8)  
    guess_vec[guess] <- "T"  
    guess_vec[-guess] <- "M"  
    sum(guess_vec == real_alloc)  
  })
```

```
## Distribution
```

```
prop.table(table(n_correct))
```

```
0 01428571 0 22857143 0 51428571 0 22857143 0 01428571
```

# Señora Degustando Té



# Señora Degustando Té Simulación

```
> ## Simulations

> sims <- 1000

> guess <- c("M", "T", "T", "M", "M", "T", "T", "M") # lady's guess

> correct <- rep(NA, sims) # place holder for number of correct guesses

> for (i in 1:sims) {
+   cups <- sample(c(rep("T", 4), rep("M", 4)), replace = FALSE)
+   correct[i] <- sum(guess == cups) # number of correct guesses
+ }

> ## comparison
> prop.table(table(correct)) - true
correct
      0      2      4      6      8
0.001714286 0.004428571 -0.015285714 0.007428571 0.001714286
```



# Fisher's Exact Test

```
> ## rows: actual assignments
> ## columns: reported guesses

> ## all correct
> x <- matrix(c(4, 0, 0, 4), byrow = TRUE, ncol = 2, nrow = 2)

> ## six correct
> y <- matrix(c(3, 1, 1, 3), byrow = TRUE, ncol = 2, nrow = 2)

> rownames(x) <- colnames(x) <- rownames(y) <- colnames(y) <- c("M", "T"
  )

> x
  M T
M 4 0
T 0 4
> y
  M T
M 3 1
T 1 3
```

# Fisher's Exact Test

```
> fisher.test(x, alternative = "greater") # one-sided
```

Fisher's Exact Test for Count Data

data: x

p-value = 0.01429

hipótesis alternativa: verdadero valor del radio de posibilidades es mas  
que 1 95 por ciento intervalo de confianza:

2.003768 Inf

estimaciones de la muestra:

radio de posibilidades

Inf

# Fisher's Exact Test

```
> fisher.test(x, alternative = "greater") # one-sided
```

Fisher's Exact Test for Count Data

data: y

p-value = 0.2429

alternative hypothesis: true odds ratio is greater than 1 95 percent

confidence interval:

0.3135693 Inf

sample estimates:

odds ratio

6.408309

# Fisher's Exact Test

```
> fisher.test(x) # two-sided
```

Fisher's Exact Test for Count Data

data: x

p-value = 0.02857

alternative hypothesis: true odds ratio is greater than 1 95 percent

confidence interval:

1.339059 Inf


sample estimates:

odds ratio

Inf

# Reanudar el experimento

```
> setwd("~/Dropbox/Experimental_Methodology/DPIR_2017/qss-master/
  CAUSALITY")
> resume <- read.csv("resume.csv")
> sims <- 5000
> z <- rep(NA, sims)
> for (i in 1:sims) {
+   ## shuffles treatment assignment
+   treat <- sample(resume$race, replace = FALSE)
+   ## test statistic
+   z[i] <- sum(resume$call[treat == "black"])
+ }
> ## observed z
> z.obs <- sum(resume$call[resume$race == "black"])
> z.obs
[1] 157
> ## one-sided p-value; proportion of simulated draws less than observed
  value
> pvalue <- mean(z[i] <= z.obs)
> pvalue
[1] 0
> ## histogram of reference distribution
> hist(z, freq = FALSE, xlim = c(150, 250),
+   xlab = "test_statistic", main = "Reference_distribution")
> abline(v = z.obs, col = "red")
> text(170, 0.035, "observed\nvalue")
```



# Comentarios Sobre la Aleatorización

- Uno obtiene arbitrariamente valores precisos de p-values sin depender en los supuestos de distribución
- El mismo método se puede utilizar para una amplia gama de aplicaciones y estadísticas de prueba (por ejemplo, diferencias en medias, regresiones, diferencias en varianzas, etc.)
- Obliga al investigador a tomar un momento para pensar cuidadosamente acerca de cuál es la hipótesis nula y cómo debe ser testeada

# Inferencia II: Intervalos de confianza de Neyman

	Porcentaje del presupuesto si el jefe de la villa es hombre	Porcentaje del presupuesto si el jefe de la villa es mujer	Efecto Tratamiento
Villa 1	10	15	5
Villa 2	15	15	0
Villa 3	20	30	10
Villa 4	20	15	-5
Villa 5	10	20	10
Villa 6	15	15	0
Villa 7	15	30	15
Promedio	15	20	5



# Inferencia II: Intervalos de confianza de Neyman

**Tabla 3.1** Distribución de muestra de EPTs estimados generados cuando dos de siete villas del listado Tabla 2.1 son asignadas para tratamiento

$\hat{\delta}_{fs}$	Frecuencia con la que un estimado ocurre
-1	2
0	2
0.5	1
1	2
1.5	2
2.5	1
6.5	1
7.5	3
8.5	3
9	1
9.5	1
10	1
16	1

# Inferencia II: Intervalos de confianza de Neyman

- Basado en los números de la Tabla 3.1, calculamos el error estándar de la siguiente manera:

*Suma del cuadrado de las desviaciones*

$$\begin{aligned} &= (-1 - 5)^2 + (-1 - 5)^2 + (0 - 5)^2 + (0.5 - 5)^2 + (1 - 5)^2 + (1 - 5)^2 \\ &+ (1.5 - 5)^2 + (1.5 - 5)^2 + (2.5 - 5)^2 + (6.5 - 5)^2 + (7.5 - 5)^2 + (7.5 - 5)^2 \\ &+ (7.5 - 5)^2 + (8.5 - 5)^2 + (8.5 - 5)^2 + (8.5 - 5)^2 + (9 - 5)^2 + (9.5 - 5)^2 \\ &+ (10 - 5)^2 + (16 - 5)^2 = 445 \end{aligned}$$

$$\text{La raíz cuadrada del promedio de las desviaciones} = \sqrt{\frac{1}{21}(445)} = 4.60$$

## Error estándar de $\hat{\delta}_{fs}$

$$\mathbb{V}(\hat{\delta}_{fs}) = \frac{N_t \mathbb{V}(Y_i(0))}{(N-1)N_c} + \frac{N_c \mathbb{V}(Y_i(1))}{(N-1)N_t} + \frac{2\text{Cov}(Y_i(0), Y_i(1))}{N-1}$$

$$EE(\hat{\delta}_{fs}) = \sqrt{\frac{1}{6} \left( \frac{(2)(14.29)}{5} + \frac{(5)(42.86)}{2} + (2)(7.14) \right)} = 4.60$$

- $i\widehat{ES}(\hat{\delta}_j)$ ?
- Los dos primeros términos son fáciles de estimar:  
podemos usar las varianzas de muestra de  $Y_i^{obs}|D_i = 1$  y  $Y_i^{obs}|D_i = 0$ , respectivamente
- La covarianza entre valores potenciales no es posible estimarla

## Error estándar de $\hat{\delta}_{fs}$

- Las varianzas nunca son negativas. Asumiendo que las varianzas son constantes, ¿cuándo es mínima la covarianza? ¿Cuándo es máxima? (recuerden que  $\text{Cov}(A, B) = \rho_{AB} \sqrt{\mathbb{V}[A] \mathbb{V}[B]}$ ).
- Cuando el efecto causal individual es constante y aditivo (i.e.  $Y_i(1) - Y_i(0) = \delta$ ),  $\rho_{Y_i(0), Y_i(1)} = 1$  y el estimador del error estándar se vuelve

$$\widehat{EE}(\delta)_{fs} = \sqrt{\frac{\widehat{\mathbb{V}}(Y_i(0))}{N_c} + \frac{\widehat{\mathbb{V}}(Y_1(1))}{N_t}}$$

- Si el efecto es heterogéneo, este estimador tiene un sesgo positivo: es conservador.

# Intervalos de Confianza

- Armados de con este estimador de la varianza de la distribución de muestreo de  $\hat{\delta}_{fs}$ , podemos construir intervalos de confianza de formas tradicionales:

$$CI^{1-\alpha}(\delta_{fs}) = \hat{\delta}_{fs} \pm z_{\alpha/2} \sqrt{\mathbb{V}(\hat{\delta})}$$

- Tuvimos que asumir que la distribución de aleatorización (i.e. la distribución de muestreo) de  $\hat{\delta}_i$  es Normal. No es muy atractivo, pero funciona en la práctica.

# Análisis de Poder

---

# Poder Estadístico

- ¿Cuál es el poder de una prueba estadística?  $H_0$ : hipótesis nula
- Aplique el estimador para probar una alternativa  $H_A$
- Error tipo I: Falso positivo
  - Si la hipótesis nula es verdad, ¿Qué probabilidad tiene que el efecto estimado (o un valor mayor) ocurra por casualidad?
  - Nuestra tolerancia a estos errores esta dada por  $\alpha$
  - Cuando  $\alpha = 0.05$ , 95% del intervalo de confianza es construido en base a varias muestras que contendrá el valor real del parámetro

- Error tipo II: Falso negativo
  - Si la hipótesis nula no es verdadera, ¿con qué frecuencia podemos rechazar la hipótesis nula con éxito?
  - Probabilidad o tasa de error tipo II,  $\beta$
- Poder de un test: Probabilidad de que la prueba rechace  $H_0$ ,  $1 - \beta$




# Inferencia Básica Revisada

- ¿Cuál es el efecto de perder Medicaid en la mortalidad infantil?
- $H_0 = 20$  muertes por cada 1,000 nacidos vivos (asumimos conocemos incertidumbre aquí)
- El verdadero efecto es un aumento de 2 muertes por cada 1,000 nacidos vivos
- La desviación estándar en la población es 4, tenemos  $N=44$  observaciones; la distribución de muestreo produce un error estándar de 0.60

# Inferencia Básica Revisada


- $\hat{x}$  es nuestro valor estimado de la nueva tasa de mortalidad infantil
- Digamos que obtenemos un estimado  $\hat{x} = 22$
- ¿Qué tan improbable es que obtengamos este estimado, si la hipótesis nula es verdadera?

# Distribución de Muestreo Bajo la Hipótesis Nula




- Digamos que nuestro test es  $\alpha = 0.05$
- Puedes cambiar la escala mediante una transformación Z
- ¿Qué significa este gráfico?
- Para  $\hat{x} = 22$ ,
- $t\text{-stat} = 3.33$ ,  
 $p = 0.0012$

# Distribución de muestreo de $\hat{x}$



- Interpretemos este gráfico
- $1 - \beta$  es la fracción de los estimados que rechazan la hipótesis nula
- Poder del test: probabilidad de identificar un efecto de un tamaño dado como significativo.
- ¿Qué parámetros se necesitan?

# La Relación entre $\alpha$ y $\beta$



# El Tamaño de la Muestra Aumenta el Poder Estadístico

- De interés primordial porque puede ser manipulada
- Ley de los grandes números: Para datos independientes, la precisión estadística de las estimaciones aumenta con la raíz cuadrada del tamaño de la muestra,  $\sqrt{n}$
- Las pruebas estadísticas generalmente tienen la forma
$$T = \hat{\theta} / \sqrt{\hat{V}(\hat{\theta})}$$
- Por ejemplo: Promedio de la distribución normal  $\theta$ , data  $y = (y_1, \dots, y_n)$ , iid

$$\hat{\theta} = n^{-1} \sum_{i=1}^n y_i = \bar{y}$$

$$\hat{V}(\hat{\theta}) = V(y)/n \text{ and } \sqrt{\hat{V}(\hat{\theta})} = s_y / \sqrt{n}$$

$$T = \bar{y} / (s_y / \sqrt{n})$$

# El Tamaño de la Muestra Aumenta el Poder Estadístico

- Esta lógica se extiende para los casos con dos muestras (por ejemplo, tratados vs control en un experimento), regresiones, regresión logística, etc.

# “Reverse Engineer T” para Determinar el Tamaño de la Muestra

- ¿Cuántas muestras necesito para darme una oportunidad “razonable” de rechazar  $H_0$ , dadas las expectativas respecto a la magnitud del “efecto”
- Ejemplo:

Una proporción  $\theta \in [0, 1]$  estimada como  $\hat{\theta}$

La varianza es  $\theta(1 - \theta)/n$ , máximo hasta 0.5

Un Intervalo de Confianza de 95%  $\theta = 0.5$  es  $0.5 \pm 2\sqrt{0.25/n}$

El ancho de ese intervalo es  $W = 4\sqrt{0.25/n} \rightarrow n = 4/W^2$



# “Reverse Engineer T” para Determinar el Tamaño de la Muestra

- Uso típico: ¿cuán grande debe ser una encuesta para obtener un margen de error razonable?
- Para los investigadores, ¿cuán grande debe ser una encuesta para detectar el efecto de un campaña?
  - La respuesta depende de la creencia que tenemos acerca de la magnitud probable de los efectos de la campaña

## Ejemplo 2: efecto campaña

- En R, `power.prop.test()`
- El investigador piensa que es probable que los efectos se mueven en una proporción entre 50% y 52% (por ejemplo, apoyo a votar)
- Desea poder detectar efectos de este tamaño en niveles convencionales de significancia estadística
- ( $p = 0.05$ ; 95% Intervalo de confianza para el efecto excluye cero), con poder  $(1 - \beta)$  igual a 0.50
- $H_0 : \delta = \theta_1 - \theta_2 = 0$ ;  $H_A : \delta \neq 0$  (Un test de dos colas es una alternativa)

# Estimación de Poder Para 2 Puntos de Efectos

Test dos colas con un nivel convencional de significancia

```
>power.prop.test(p1 = 0.5, p2 = 0.52, power  
= 0.5)
```

Comparación de dos muestras de cálculo de potencia de proporciones

$n = 4799.903$

$p1 = 0.5$

$p2 = 0.52$

$\text{sig.level} = 0.05$

$\text{power} = 0.5$

$\text{alternative} = \text{two.sided}$

NOTE: n is number in *\*each\** group

# Estimación de Poder Para 2 Puntos de Efectos

Test unilateral con un nivel de convencional de significancia

```
> power.prop.test(p1 = 0.5, p2 = 0.52,  
  power = 0.5,  
  alternative="one.sided")
```

Comparación de dos muestras de cálculo de potencia de proporciones

$n = 3380.577$

$p1 = 0.5$

$p2 = 0.52$

$\text{sig.level} = 0.05$

$\text{power} = 0.5$

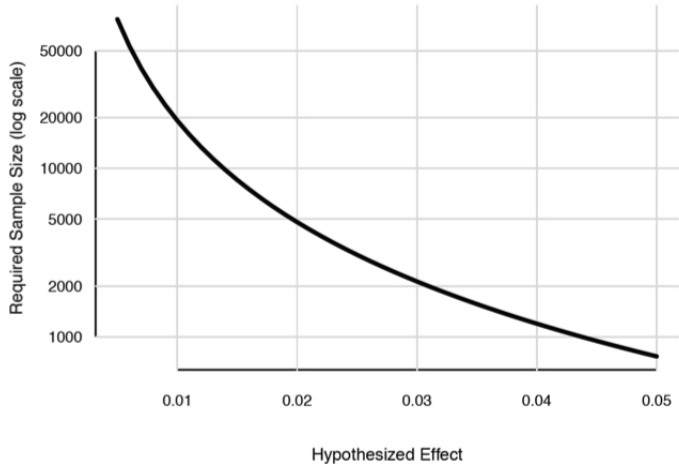
$\text{alternative} = \text{one.sided}$

NOTE: n is number in \*each\* group

# Curvas de Poder

```
> p> effects <- seq(0.005, 0.05, by =  
  0.001)  
  
> base <- 0.5  
> m <- length(effects)  
> n <- rep(NA, m)  
> for (i in 1:m) {  
  n[i] <- power.prop.test(p1 = base, p2 =  
    base + effects[i],  
+ power = 0.5)$n  
+})
```


# Curvas de Poder



# Curvatura de las Curvas de Poder

```
> power <- c(0.5, 0.75, 0.9, 0.95, 0.99)
> effects <- seq(0.01, 0.05, by = 0.001)
> base <- 0.5
> m <- c(length(power), length(effects))
> n <- matrix(NA, m[1], m[2])
> for (i in 1:(m[1])) {
+   for (j in 1:(m[2])) {
+     n[i, j] <- power.prop.test(p1 = base, p2
+       = base + effects[j],
+     power = power[i])$n
+   }
+ }
```

# Curvas de Poder: Diferentes Niveles de Poder





# Consejos Prácticos Sobre el Análisis de Poder

- Cuál es el tamaño "típico" de los efectos, y cómo podríamos adivinarlo?
  - Algunas reflexiones sobre un ejemplo posterior
- Generalmente, los estudios experimentales requieren  $1 - \beta > 0.8$  cuando se solicitan fondos a agencias
- Máxima de Zaller: "Haga su análisis de poder, determina el tamaño de su muestra, luego dobla ese numero"

# Consejos Prácticos sobre el Análisis de Poder

- Consideraciones de costos: Gerber y Green experimento en New Haven GOVT
  - Uno de los componentes involucró la prospección
  - \$40 por hora con un par de estudiantes, 6,000 tratados
  - Son 6 casas por hora, necesitas 1000 horas, por lo que son \$40k
  - Implicaciones basadas en diapositivas de curva de potencia
- En particular, los costos son altos para los experimentos que buscan evaluar a la población en general
- ¿Alguien tiene una idea de cuánto cuestan las encuestas?
- ¿Cuánto es su valor?