### Escuela de Invierno CESS 2017

### Experimentos de laboratorio

CESS Santiago — Julio 21, 2017

David Klinowski

Centre for Experimental Social Sciences (CESS) Nuffield College, University of Oxford University of Santiago de Chile

### Índice

- 1. ¿Qué es un experimento de laboratorio en las ciencias sociales?
- 2. Procedimientos y sus razones
- 3. Ventajas del laboratorio
- 4. Críticas al laboratorio
- 5. Ejemplo
- 6. Cómo diseñar un experimento de laboratorio

# ¿Qué es un experimento de laboratorio en las ciencias sociales?

### Existen 2 distintas acepciones:

- Situación de toma de decisiones en entorno altamente controlado (no necesariamente con distintos tratamientos)
- Asignación aleatoria y deliberada por el investigador a tratamiento(s) o control

El primero investiga patrones de comportamiento y mecanismos; el segundo busca establecer causalidad.

Ej 1: juego de bien público por 10 rondas

Posibles hallazgos:

- individuos contribuyen más que cero
- contribución cae con el tiempo
- género, edad, tolerancia al riesgo, altruismo, etc. predicen el nivel de contribución (no implica causalidad)

No hubo tratamientos, pero sí ambiente controlado y medición de covariables

Ej 2: juego de bien público por 10 rondas, dos versiones (tratamientos)

- T1: sin posibilidad de sanción
- T2: con posibilidad de sanción
- comparar resultados T1 vs. T2 permite examinar el efecto de la posibilidad de sanción sobre el nivel de contribución
- posible hallazgo: la posibilidad de sanción aumenta el nivel de contribución (causalidad)

Consideraciones de diseño: ¿tratamiento intra- o inter-sujetos? ¿cuántos elementos se varían de T1 a T2 y cuál es un control apropiado?

- Se tiende a pensar que el experimento aleatorizado (acepción 2) es el método por excelencia y por ende superior a un experimento en toma de decisiones (acepción 1)
- Sin embargo son métodos distintos que persiguen conocimiento distinto (documentar un fenómeno vs. estimar un efecto)
- Además no son mutuamente excluyentes
- El experimento aleatorizado no está exento de crítica, y una de las principales críticas se mitiga combinando los 2 métodos

### Crítica a los experimentos aleatorizados

"[...] learning about development requires us to investigate mechanisms. Finding out about how people in low-income countries can and do escape from poverty is unlikely to come from the empirical evaluation of actual projects or programs, whether through randomized trials or econometric methods that are designed to extract defensible causal inferences, unless such analysis tries to discover why projects work rather than whether they work." Deaton (2010), Premio Nobel 2015

- La crítica de Deaton puede aplicar a los experimentos aleatorizados en el laboratorio: encontrar que un tratamiento tiene un efecto no significa saber por qué tiene un efecto
- Saber el porqué es relevante para avanzar el conocimiento (diseño de nuevas preguntas y experimentos) y diseñar políticas efectivas
- en nuestro ej. saber si la sanción tiene un efecto mediante un mayor monitoreo, un aumento de confianza en que otros contribuirán, señalización de que no contribuir es mal visto, o el prospecto de perder dinero implicaría distintos nuevos experimentos y políticas

¿Cómo investigar por qué la sanción tiene un efecto?

¿Cómo investigar por qué la sanción tiene un efecto?

- 1. Experimento aleatorizado con múltiples tratamientos
  - T1: sin posibilidad de sanción
  - T2: revelando identidad y contribuciones individuales
  - T3: realizando contribuciones secuenciales
  - T4: sancionando con puntos simbólicos

- ¿Cómo investigar por qué la sanción tiene un efecto?
- 2. Estimar heterogeneidad del efecto de tratamiento a covariables relevantes
  - T1: sin posibilidad de sanción
  - T2: con posibilidad de sanción
  - medir interacción del efecto de tratamiento con: atención a la información sobre acciones de los demás, expectativas de que otros contribuirán, impresión sobre valor de contribuir, niveles de cooperación, confianza, altruismo, tolerancia al riesgo, etc. en tareas separadas

### En conclusión

- un experimento puede o no tener tratamientos
- el uso de tratamientos depende de si el objetivo es estimar el efecto causal
- cuando el objetivo es no solo estimar el efecto sino también entender sus mecanismos de acción, es útil diseñar múltiples tratamientos o estimar heterogeneidad del efecto del tratamiento

Más allá de esto, un experimento de laboratorio en ciencias sociales se distingue comúnmente (Harrison and List 2004) por:

- realizarse en el laboratorio (duh!, aunque según Charness, Gneezy, Kuhn 2013 puede haber un experimento de campo en el laboratorio cuando el laboratorio es el contexto representativo)
- muestra de conveniencia (estudiantes como participantes)
- además, en economía y ciencia política, se siguen ciertos procedimientos estándar

Las disciplinas de economía y ciencia políticas han convergido a una serie de procedimientos para experimentos de laboratorio que ya no solo se consideran buenas prácticas, sino que también son requisitos para realizar trabajos en muchos centros (ej. CESS) y publicar en revistas académicas. Veamos estos procedimientos y sus razones examinando paso a paso cómo transcurre un experimento de laboratorio típicamente.

- 1. Buscar participantes de entre una "muestra de conveniencia"
  - estudiantes universitarios (conveniente para investigadores en la misma universidad)
  - si se recluta también para experimentos futuros, se invita a personas a compartir su email para recibir invitaciones cada vez que haya un experimento
  - en este caso preferiblemente se ingresa su email a una base de datos manejada por software especializado (ej. <u>ORSEE</u> o <u>Sona Systems</u>) para controlar comunicaciones, historial de participación, criterios de exclusión/inclusión, etc.

- 2. Invitar a participar en experimento según criterios de inclusión/exclusión
  - experimento típico consiste de múltiples sesiones de 1-2 hr cada una (ej. 120 participantes en sesiones de 24 = 5 sesiones)
  - programar y ejecutar sesiones en condiciones similares (horario, experimentador)
  - invitar a más participantes de lo necesario para contrarrestar ausencias (pagar "show-up fee" a excendente y permitir registrarse en otra sesión)
  - información a incluir: potencial pago, duración de experimento, facilidad de horario, ayuda a la ciencia

### 3. Obtener consentimiento informado

- obtener antes de comenzar sesión
- información a incluir: riesgo de daño y posibles beneficios; participación es voluntaria con derecho a retirarse en cualquier momento; privacidad y anonimidad de participación, decisiones y datos (de ser así); prohibición del engaño; posibles pagos; datos de contacto del investigador o comité en caso de quejas
- dar al participante opción de mantener una copia
- asegurarse de que el participante firme
- en caso de vergüenza a negarse a participar, informar en la invitación en vez de en el lab
- Ejemplo de planilla de consentimiento

¿Por qué no engañar?

- para asegurarse que los participantes responden a los incentivos presentados
- el panel de participantes es un bien público para otros investigadores

- 4. Proveer instrucciones al inicio y durante la sesión
  - escritas (preferiblemente en el monitor en vez de papel para evitar escape de información) y leídas en voz alta para establecer conocimiento común
  - normalmente uso de lenguaje neutro (términos concretos ej. "empleado" pueden ayudar a la comprensión y acercamiento al contexto de interés pero disminuyen el control sobre los conceptos que perciben los participantes)

- 4. Proveer instrucciones al inicio y durante la sesión
  - presentar ejemplos o quiz de comprensión para evitar ruido, cuidando no sugerir comportamiento en específico y usando información de comprensión como test de robustez en el análisis
  - responder preguntas en privado para mantener control e igualdad de las sesiones

- 5. Participantes toman decisiones, expresan opiniones, proveen información
  - normalmente de forma privada y anónima a menos que se quiera estudiar el rol de la identidad (en cuyo caso normalmente se usan fotos o cara a cara)
  - variables que difícilmente cambian y que pueden sugestionar el comportamiento (ej. género, raza, nivel socioeconómico) se preguntan al final a menos que se busque sugestionar el comportamiento
  - interfaz preferiblemente computarizada para agilizar sesión y recabación de datos y aumentar capacidad de alcance (plataformas típicas zTree, oTree, Qualtrics, papel y lápiz)

### 6. Decisiones incentivadas monetariamente

- pago no solo por participar sino de acuerdo a sus decisiones y las de los demás
- tareas son "compatibles en incentivos": incentivos están alineados con las preferencias y no es rentable mentir
- participantes no pueden salir con menos dinero del que ingresan
- se revela información de ganancias solo al final para mantener comparabilidad entre sujetos (y rondas intra-sujetos) y evitar efectos de ganancias

- 6. Decisiones incentivadas monetariamente
  - pago de una(s) ronda(s) o tarea(s) o participante(s) escogida al final al azar para reducir costos y al mismo tiempo mantener incentivos en todas las tareas
  - pago en efectivo (para evitar "saciedad") al final de la sesión
  - promedio en CESS Santiago: 8 USD por hora

¿Por qué incentivar decisiones monetariamente?

- gran parte del comportamiento de interés es en respuesta a beneficios y costos — nos interesa que los participantes incurran en ellos
- lo que uno dice que hará no es necesariamente lo que hará cuando hay algo en juego

¿Por qué incentivar decisiones monetariamente?

- sin embargo cabe notar que en la literatura no está claro si (y cuándo) usar incentivos afecta el comportamiento (Camerer & Hogarth 1999, Bonner et al. 2000): (i) no afectan el comportamiento promedio en situaciones de mercado como negociación, intercambio, adquisición de riesgo; (ii) afecta el comportamiento promedio en situaciones donde mayor esfuerzo resulta en mejor rendimiento; (iii) en general reduce la varianza en el comportamiento
- además cabe notar que teorías exitosas (ej. prospect theory) e índices económicos (pib, inflación) se construyen con auto-reportes no incentivados

Además de los procedimientos durante el experimento, hay pasos previos que el experimentador debe cumplir antes de realizar el experimento

- entrenamiento ético
- aprobación ética del experimento
- pre-registro del experimento

### 0.1. Entrenamiento ético

- el investigador debe entender las responsabilidades de trabajar con sujetos que son seres humanos
  - garantizar participación voluntaria e informada en todo momento
  - minimizar riesgos y maximizar beneficios
  - asegurar la confidencialidad y de-identificación de la participación y datos
- el investigador debe demostrar entrenamiento ético para obtener fondos, ingresar proyectos en centros como CESS, publicar estudios
- entrenamiento ético en español, abierto y gratis en USA NIH

### 0.2. Revisión ética del experimento

- comité externo evalúa eticalidad de la propuesta
- generalmente las universidades poseen un comité
- importante considerar que puede demorar semanas
- ejemplo de aplicación ética CESS

### 0.3. Pre-registro

- una propuesta para enfrentar el reporte selectivo de resultados positivos
  - "p-hacking" o "data fishing"
  - el reporte selectivo desvirtua el p-valor

Ej. simplificado de cómo el reporte selectivo desvirtua el p-valor:

- supongamos que tenemos un dado con 100 lados (1-100)
- si lo lanzamos una vez, la prob. de caer en 96-100 es
  - p(96-100, 1 | lanzamiento) = 0.05
- supongamos que nuestro ejercicio es lanzar el dado una vez y concluir que está sesgado si cae 96-100

Ej. de cómo el reporte selectivo desvirtua el p-valor:

- si lanzamos el dado más de una vez, pero solo reportamos que lo lanzamos una vez
  - p(no 96-100, 1 | lanzamiento) = 0.95
  - $p(\text{no }96\text{-}100, 2 \text{ lanzamientos}) = (0.95)^2$
  - $p(96-100 \text{ al menos una vez, 2 lanzamientos}) = 1 (0.95)^2 = 0.0975$
  - $p(96-100 \text{ al menos una vez, } 3 \text{ lanzamientos}) = 1 (0.95)^3 = 0.1423$
- la probabilidad de obtener 96 100 ya no es 0.05
- problema: el reporte selectivo introduce mayor número de falsos positivos (resultados y conclusiones falsas) en la literatura científica y el conjunto de conocimientos

solución 1: reporte transparente de todos los procedimientos experimentales y de análisis

- pero esto puede volver al manuscrito muy incómodo de escribir y leer
- pero esto requiere confiar en la transparencia del investigador que reporta

### solución 2: pre-registro

- es un documento que describe el diseño experimental y plan de análisis antes de comenzar a recabar datos
- permite separar testeo de hipótesis de análisis exploratorio
- debe registrarse (fechado e inalterable) para que su valor añadido aplique
  - lista de registros
  - aspredicted.org
- plantilla de plan de pre-análisis de Alejandro Ganimian

### solución 3: replicaciones

- movimiento impulsado por experimentalistas de laboratorio
- permiten identificar falsos positivos ex-post
- no muchas pero cada vez más revistas aceptan replicaciones explícitamente

## Ventajas del laboratorio

### Ventajas del laboratorio

- alto control
  - asegura que los participantes hacen lo que uno cree que hacen
  - bajo desgaste, cumplimiento completo
  - alta validez interna
  - permite medir variables relevantes y prácticamente inaccesibles de otra manera
- alta replicabilidad, pilar del avance del conocimiento en la ciencia
- relativamente rápida logística y ejecución del experimento (importante considerar para tesis)

- participantes son objeto de escrutinio sin precedente
- contexto abstracto o poco realista
- participantes no son representativos de la población general
- resultados no generalizan (poca validez externa)

#### Crítica: alto nivel de escrutinio

• crea "experimenter demand effects"

- permite alto control, validez interna, replicabilidad, a nivel imposible en el campo u online
- no existe evidencia de tal efecto (Camerer 2015)
- requiere que los participantes conozcan de antemano la hipótesis del investigador
- requiere que los participantes estén dispuestos a sacrificar sus ganancias para complacer al experimentador
- muchos experimentos de campo también involucran escrutinio, por ONG's

Crítica: contexto abstracto y poco realista

- permite aislar el mecanismo de interés y "apagar" otros canales, de nuevo potenciando la validez interna
- incentivos monetarios nos ganan realismo
- acciones en privado a través del computador son cada vez más normales
- el laboratorio, como cualquier otra herramienta, es ideal para ciertas preguntas y no para otras

Crítica: estudiantes son un grupo altamente seleccionado Respuesta:

- cierto: participantes son aquellos dispuests a compartir su email, incluir el experimento en su agenda, hacer el esfuerzo de llegar al lab a tiempo, dar consentimiento informado...
- si es crucial llegarle a una población en particular, se puede llevar el lab a ellos

Crítica: poca validez externa.

"Perhaps the most fundamental question in experimental economics is whether findings from the lab are likely to provide reliable inferences outside the laboratory." Levitt y List (2007)

Crítica: poca validez externa.

- el laboratorio no necesariamente tiene poca validez externa—depende de la pregunta
  - efecto de mostrar cierta inforamción sobre donación al momento de realizar una transacción a través del computador
  - exámenes estandarizados
- ciertamente no es la herramienta correcta para investigar ciertas preguntas (ej. efecto de los uniformes sobre la asistencia escolar)

Crítica: poca validez externa.

- esto asume "visión de política pública" de los experimentos, pero en la "visión científica" toda evidencia es útil para avanzar el conocimiento y es igual preguntar si el campo se generaliza al lab (Camerer 2015)
  - ej. en psicología hay experimentos sobre la memoria, atención, percepción y sensaciones que son totalmente válidos y útiles para el conocimiento científico
  - así mismo nos puede interesar estudiar el comportamiento, la racionalidad, etc. independientemente de la visión de política pública

Crítica: poca validez externa.

- el campo también puede sufrir de poca validez externa (RCTs dependen del contexto, participantes, implementador)
- visión más mesurada: obtener validez externa es importante y posible (Kessler y Vesterlund 2015)
- si desea generalizar, le incumbe al experimentador demostrar la validez externa

Crítica: poca validez externa.

- reciente esfuerzo por combinar experimentos de laboratorio con datos administrativos para investigar la validez externa
- veremos un ejemplo

Diferencias de género en disposición a competir

- experimento de laboratorio "sin tratamientos"
- replicado en 15+ experimentos de laboratorio
- reciente esfuerzo de experimentalistas por establecer validez externa combinando experimento con datos administrativos

\*Niederle, M. and Vesterlund, L. (2007). "Do women shy away from competition? Do men compete too much?" The Quarterly Journal of Economics 122(3):1067-1101.

\*Reuben, E., Sapienza, P., and Zingales, L. (2016). "Taste for competition and the gender gap among young business professionals" Working Paper.

#### Motivación

- persistente brecha de género en el mercado laboral
  - menor ingreso
  - menor representación en posiciones de liderazgo
- las principales explicaciones:
  - preferencia de las mujeres por flexibilidad
  - diferencias en habilidades
  - discriminación
- explicación adicional examinada experimentalmente: mujeres son menos competitivas que los hombres
  - reacias a entrar a carreras competitivas (mejor pagadas)
  - reacias y menos efectivas en negociar aumentos y ascensos

### Niederle, M. and Vesterlund, L. (2007)

- objetivo:
  - documentar un fenómeno: brecha de género en disposición a optar por un esquema de remuneración competitivo
  - investigar los mecanismos detrás de la brecha
- posibles mecanismos:
  - actitud a la competencia (hipótesis principal)
  - habilidad
  - opinión sobre el desempeño relativo
  - tolerancia al riesgo y a recibir información negativa
  - preocupación de no imponer externalidad a los demás
- desentrañar cada mecanismo presenta el típico problema de diseño experimental

#### Experimento:

- participantes sentados en filas de 4 forman un grupo (2 hombres y 2 mujeres, pero sin énfasis en género)
- cada participante tiene 5 min para sumar la mayor cantidad de sets de 5 números aleatorios

$$57 + 33 + 18 + 11 + 49 =$$
 $23 + 44 + 31 + 33 + 60 =$ 
 $84 + 12 + 78 + 15 + 21 =$ 
 $59 + 59 + 27 + 83 + 32 =$ 
 $43 + 75 + 11 + 74 + 52 =$ 

#### Experimento:

- participantes sentados en filas de 4 (2 hombres y 2 mujeres) forman un grupo
- cada participante tiene 5 min para sumar la mayor cantidad de sets de 5 números aleatorios
- en cada suma el participante recibe información sobre si la respuesta fue o no correcta, pero ninguna información sobre el desempeño de los demás o la posición relativa hasta el final de la sesión

#### 4 partes

- solo una se paga aleatoriamente al final del experimento
- participantes saben que habrá 4 partes, pero las instrucciones para cada una de ellas se dan al principio de cada una (para evitar interacciones entre partes)

- Parte 1: recibe simple pago de \$0.50 por unidad
- Parte 2: el miembro de grupo con mayor rendimiento recibe \$2 por unidad, el resto recibe \$0
- Parte 3: escoge entre recibir simple pago de \$0.50 por unidad o recibir \$2 por unidad si supera al rendimiento de los demás en la Parte 2
- Parte 4: escoge entre recibir simple pago de \$0.50 por unidad o recibir \$2 por unidad si su rendimiento en la Parte 1 supera al rendimiento de los demás en la Parte 1 (no hay sumas en esta parte)
- antes de finalizar, adivinar propio ranking en Parte 1 y Parte 2, recibe \$1 si acierta

Variable resultado de interés:

 proporción de hombres vs. mujeres que escogen competir en la Parte 3

¿Entonces por qué tantas otras partes?

- si el objetivo fuese solo documentar una brecha de género en la competitividad, bastaría con la Parte 3
- pero el objetivo también es explorar a qué se debe tal brecha (para profundizar conocimiento y sugerir soluciones)

- Partes 1 y 2 sirven para medir habilidad en la tarea bajo pago regular y torneo
  - si las mujeres compiten menos que los hombres en el experimento, ¿se debe a que tienen menor habilidad en la tarea de sumas?
  - también permite determinar si, al decidir competir, el participante está tomando la decisión que maximiza sus ganancias (ceteris paribus)

¿Por qué tantas partes?

• Partes 3: ¿Por qué competir contra puntaje de alguien en la Parte 2?

- Partes 3: ¿Por qué competir contra puntajes de la Parte
   2?
  - si las mujeres compiten menos que los hombres en el experimento, ¿se debe a que tienen mayor preocupación por no afectar el pago del resto del grupo?
  - para anular el mecanismo de preferencias sociales
  - para competir con contrincantes que también están en un torneo
  - ¿con quién competiría si alguien del grupo decide no competir?

- Parte 4 sirve para anular la aversión al riesgo y a la información negativa en una decisión lo más cercana a la de competir, pero sin el elemento de tener que competir
  - si las mujeres compiten menos que los hombres en el experimento, ¿se debe a que tienen mayor aversión al riesgo o a recibir información negativa?
  - diseño de sustracción: si la brecha aparece (o es mayor) en la Parte 3 pero no en la Parte 4, el hacer la tarea bajo competencia como tal (que es la única diferencia) juega un rol en producir la brecha

- adivinar propio ranking sirve para medir creencia sobre habilidad absoluta y relativa
  - si las mujeres compiten menos que los hombres en el experimento, ¿se debe a que tienen menor confianza en su ranking en el grupo?

#### Resultados, sin entrar en detalles:

- hombres y mujeres tienen la misma habilidad: 10 puntos en Parte 1 y 12 puntos en Parte 2
- 35% de las mujeres y 73% de los hombres deciden competir en la Parte 3
- 25% de las mujeres y 55% de los hombres deciden ingresar su puntaje de la Parte 1 al torneo en la Parte 4
- 43% de las mujeres y 75% de los hombres creen que son los mejores del grupo (ambos géneros tienen excesiva confianza, pero más común en los hombres)
- la brecha de la Parte 4, mas no la de la Parte 3, se explica totalmente por diferencias en auto-confianza

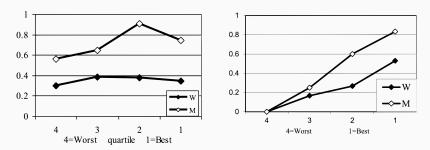


Figure 1: Proportion of participants selecting the tournament: (a) depending on performance quartile, (b) depending on believed performance rank, for women (W) and men (M), separately.

#### Conclusión:

 las mujeres son menos competitivas que los hombres aún cuando tienen la misma habilidad, y más allá de el rol que juegan la auto-confianza, tolerancia al riesgo y aversión a la información

- estudio publicado hace 10 años
- resultado replicado 15+ veces en el laboratorio
- pero, ¿de verdad explica las brechas que se observan en el mercado laboral?

Reuben, E., Sapienza, P., and Zingales, L. (WP)

#### Diseño:

- experimento similar al anterior
- participantes son estudiantes entrando al MBA del Chicago Booth
- se combinan resultados de competitividad con datos administrativos:
  - admisión (sociodemografía y récord académico)
  - egresión (ingreso e industria en primer trabajo luego de graduarse)
  - encuesta 7 años después de experimento sobre progresión laboral

Reuben, E., Sapienza, P., and Zingales, L. (WP)

#### Resultados:

- mujeres ganan 15% menos que los hombres al egresar
- mujeres tienen 8(12)% mayor probabilidad de trabajar en industrias peor pagadas al egresar (7 años después)
- participantes que deciden competir en el experimento ganan \$15k más al egresar (controlando por género)
  - la competitividad explica separadamente 10% de la brecha de género
- participantes que deciden competir tienden a trabajar en industrias mejor pagadas al egresar y 7 años después

# Cómo diseñar un experimento

de laboratorio

- hemos hablado de cómo ejecutar un experimento
- en otra sesión hablaremos de cómo programar un experimento
- para finalizar hoy, veamos pasos y tips para diseñar un experimento, en referencia al ej. de competitividad

- formular una pregunta de investigación
  - ¿puede estudiarse en lab y mantener relevancia?
  - la brecha de género en el mercado laboral es un tema complejo y sin embargo el lab arroja luz
- definir la variable resultado
  - simple decisión binaria de si competir o no
- definir los tratamientos, si existen
  - versiones de un mecanismo que se quiere evaluar
  - versiones del experimento que anulan alternativas de acción
- si hay tratamientos, ¿se administran intra- o inter-sujeto?

- identificar variables de control valiosas para el análisis
- definir número de participantes y sesiones
  - dado por número de observaciones independientes requeridas, capacidad del laboratorio, interacción entre sujetos, análisis de subgrupos, etc.
- ¿computarizado o en lapiz y papel?
  - computarizar ahorra tiempo de sesión, digitalización de datos, permite llegar a más participantes, crear interacciones entre participantes, presentar mayor variedad de estímulos
- escribir instrucciones
- escribir guión

- simplificar al máximo Einstein: "Everything should be made as simple as possible, but no simpler"
  - saber precisamente cómo se analizarán los datos generados
- el experimentalista se caracteriza por intervenir el entorno para generar sus propios datos
  - la calidad de los datos es la responsabilidad del experimentalista